MAT02038

Análise de Sobrevivência

Instituto de MATEMÁTICA E ESTATÍSTICA
UFRGS

DEPARTAMENTO DE ESTATÍSTICA

Aula 3: 12/03/2026

Prof. Dra Patrícia K. Ziegelmann

Análise Descritiva de Dados de Sobrevivência

Nos textos básicos de estatística, uma análise descritiva consiste essencialmente em encontrar medidas de tendência central e variabilidade. Como a presença de censuras invalida este tipo de tratamento aos dados de sobrevivência, o principal componente da análise descritiva envolvendo dados de tempo de vida é a função de sobrevivência. Nesta situação, o procedimento inicial é encontrar uma estimativa para esta função de sobrevivência e então, a partir dela, estimar as estatísticas de interesse que usualmente são o tempo médio ou mediano, alguns percentis ou certas frações de falhas em tempos fixos de acompanhamento.

Exemplo Didático: Divórcio

Marco inicial: Casamento

Métrica: tempo em anos

Evento: Divórcio

Tempo máximo de seguimento: 29 anos

Dados observados (n=20)

Serão considerados 3 casos:

ID	tempo	evento_caso1	evento_caso2	evento_caso3
1	2	1	1	1
2	4	1	0	0
3	5	1	1	1
4	5	1	0	0
5	5	1	1	1
6	11	1	0	0
7	11	1	1	1
8	11	1	1	1
9	11	1	1	1
10	15	1	1	1
11	15	1	1	1
12	15	1	1	1
13	19	1	1	1
14	19	1	1	1
15	20	1	1	0
16	20	1	1	1
17	20	1	1	0
18	20	1	1	0
19	20	1	1	0
20	29	1	1	1

Estimação da Função de Sobrevivência

1. Métodos Não- Paramétricos

    Estimador Tábua de Vida

    Estimador de Kaplan-Meyer

    Estimador de Nelson-Aalen

2. Métodos Paramétricos

    Modelo Exponencial

    Modelo Weibul

    Modelo Gompertz, etc...

Estimador Tábua de Vida

Os dados observados são categorizados em classes

ID	tempo	evento_caso1
1	2	1
2	4	1
3	5	1
4	5	1
5	5	1
6	11	1
7	11	1
8	11	1
9	11	1
10	15	1
11	15	1
12	15	1
13	19	1
14	19	1
15	20	1
16	20	1
17	20	1
18	20	1
19	20	1
20	29	1

Anos pós casamento	N de Divórcios	N de Censuras
0 – 9	5	0
10 – 19	9	0
20 - 29	6	0
Total	20	0

Considera probabiloidades condicionais do tipo

$$S(t) = P(T \geq t) = P(T \geq 0) \times P(T \geq 1 \mid T \geq 0) \times \ldots \times P(T \geq t \mid T \geq t\text{-}1)$$

Anos pós casamento	N de Divórcios	N de Censuras
0 – 9	5	0
10 – 19	9	0
20 - 29	6	0
Total	20	0

Probabilidade de um casamento completar 10 anos (sobreviver a 10 anos)

Intervalo (anos)	Nº em risco	Nº de falhas	Prob. falha	Prob. sobrev.	Prob.acumul. de sobrev.(S)
0 - 9	20	5	0,25	0,75	0,75
10 - 19	15	9	0,60*	0,40	0,30**
20 - 30	6	6	1	0	0

Probabilidade de um casamento completar 20 anos

* 9/15 = 0,60 ** 0,40 x 0,75 = 0,30

Probabilidade de um casamento que entrou na segunda década completar 20 anos

Intervalo (anos)	Nº em risco	Nº falhas	Prob falha	Prob sobrev	Prob acumul. de sobrev (S)
0 - 9	20	5	0,25	0,75	0,75
10 - 19	15	9	0,60	0,40	0,30
20 - 30	6	6	1	0	0

Curva de Sobrevivência estimada

Representação Gráfica

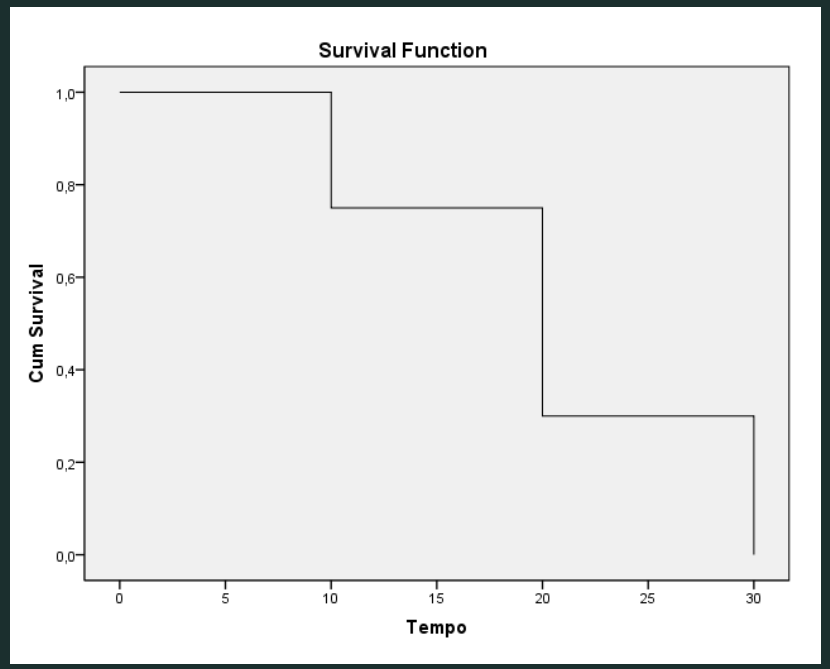

Note que a curva termina em 0 no tempo máximo de seguimento.

Estimador Tábua de vida

Caso 2 (com censura nas duas primeiras classe de tempo)

Anos pós casamento	N de Divórcios	N de Censuras
0 – 9	3	2
10 – 19	8	1
20 – 29	6	0
Total	17	3

Intervalo (anos)	Nº inicial	Divór-cios	Censura	Nº sob risco *	Prob falha	Prob sobrev	Prob acumul. sobrev (S)
0 - 9	20	3	2	19	0,16	0, 84	0,84
10 - 19	15	8	1	14,5	0,55	0,45	0,38
20 - 30	6	6	0	6	1,00	0,00	0,00

* Retirando a metade dos indivíduos censurados

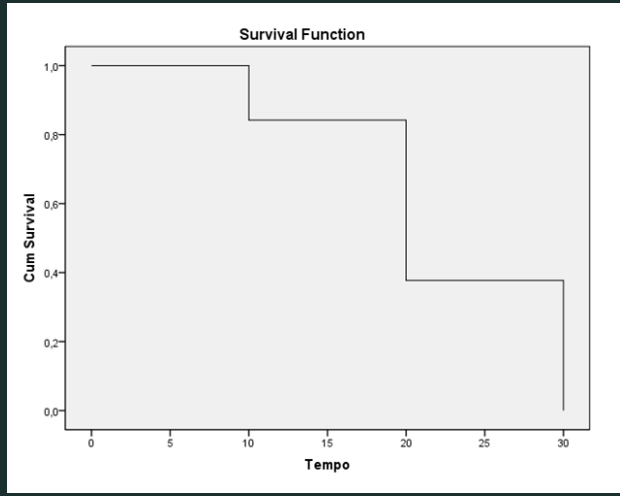

Estimador Tábua de vida

Exemplo 2 (com censura no ultimo período):

Anos pós casamento	N de Divórcios	N de Censuras
0 – 9	3	2
10 – 19	8	1
20 – 29	2	4
Total	13	7

Intervalo (anos)	Nº inicial	Divór-cios	Censura	Nº sob risco *	Prob falha	Prob sobrev	Prob acumul. sobrev (S)
0 - 9	20	3	2	19,0	0,16	0,84	0,84
10 - 19	15	8	1	14,5	0,55	0,45	0,38
20 - 30	6	2	4	4,0	0,50	0,50	0,19

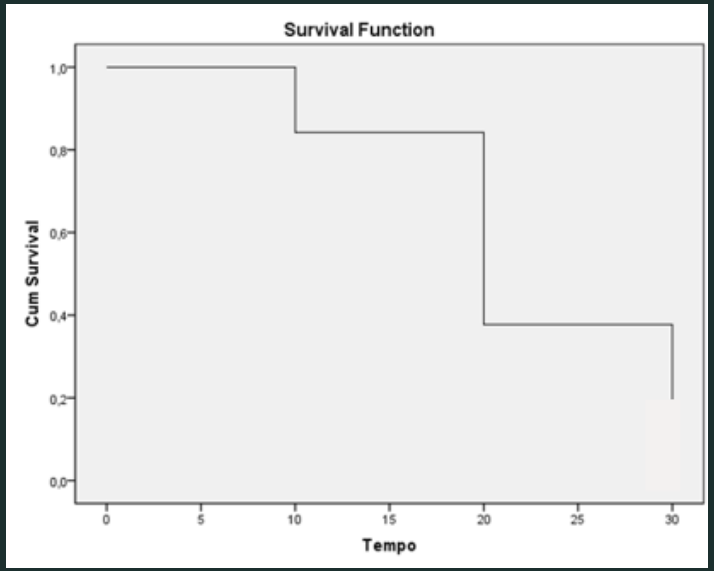

Comparando estimativas
Sem e Com censura

Exemplo 1
Sem Censura

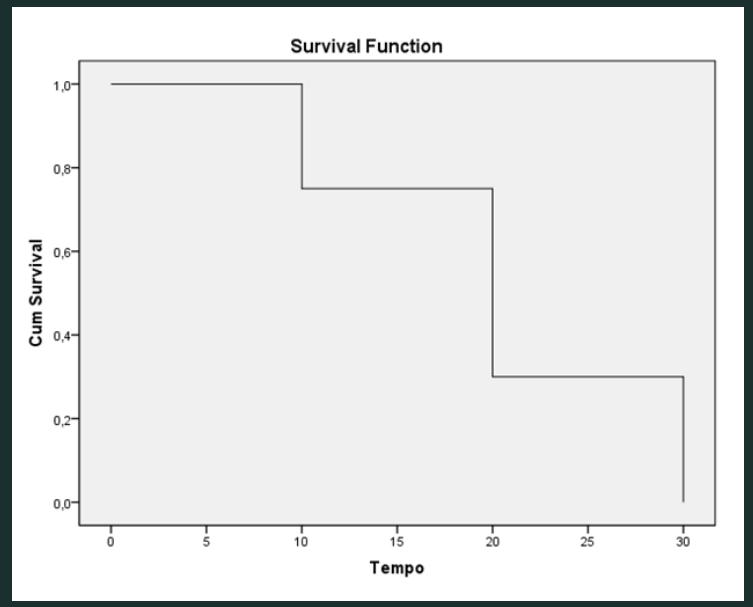

Exemplo 2
Censura nos 2 primeiros

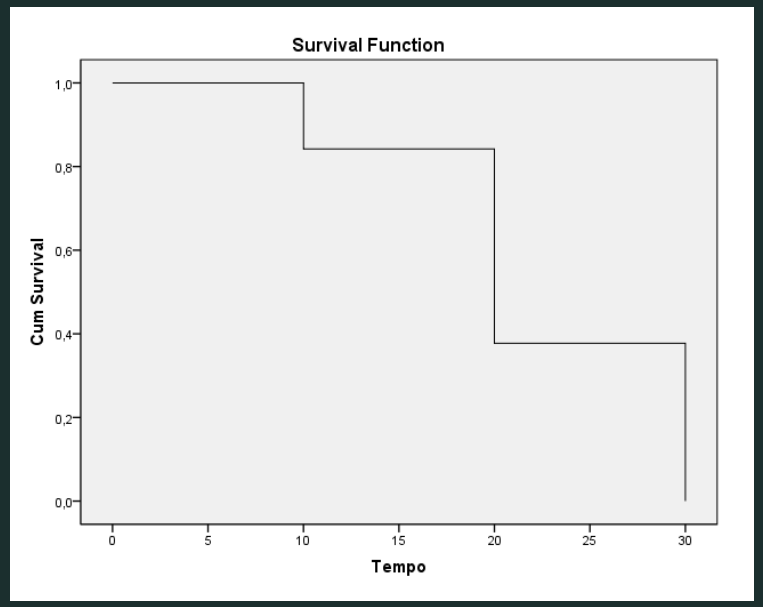

Exemplo 3
Censura nos 3 períodos

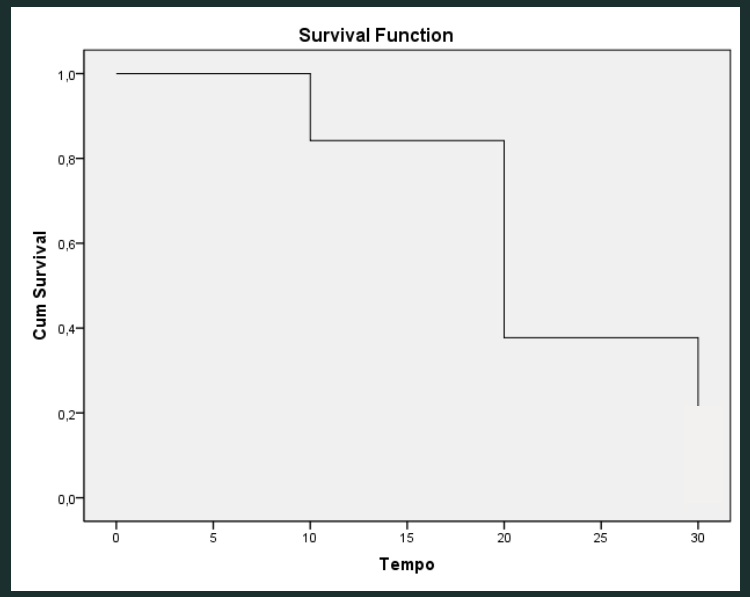

Censuras são “tratadas” como se estivessem sob risco durante a metade do período considerado

Estimador Kaplan-Meier

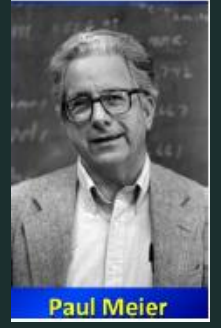

Método não-paramétrico para estimar curvas de sobrevivência proposto por Kaplan e Meyer em 1958.

Adaptação da função de sobrevivência empírica utilizada nas tábuas de vida

Considera tantos intervalos de tempo quantos forem o número de eventos em tempos distintos.

Estimador Kaplan-Meier

$$S(t) = P(T \geq t) = P(T \geq 0) \times P(T \geq 1 \mid T \geq 0) \times \ldots \times P(T \geq t \mid T \geq t-1)$$

- O estimador KM é dado por: $\hat{S}(t) = \prod_{j:t_j<t} \left(\frac{n_j - d_j}{n_j} \right)$
- $t_1 < t_2 < \ldots < t_k$ são os k tempos de evento distintos
- d_j é número de eventos no tempo t_j
- n_j é número de "indivíduos" sob risco (não tiveram evento e não foram censurados) até o instante imediatamente anterior ao tempo t_j

Estudo Divórcio utilizando KM

ID	tempo	evento_caso1
1	2	1
2	4	1
3	5	1
4	5	1
5	5	1
6	11	1
7	11	1
8	11	1
9	11	1
10	15	1
11	15	1
12	15	1
13	19	1
14	19	1
15	20	1
16	20	1
17	20	1
18	20	1
19	20	1
20	29	1

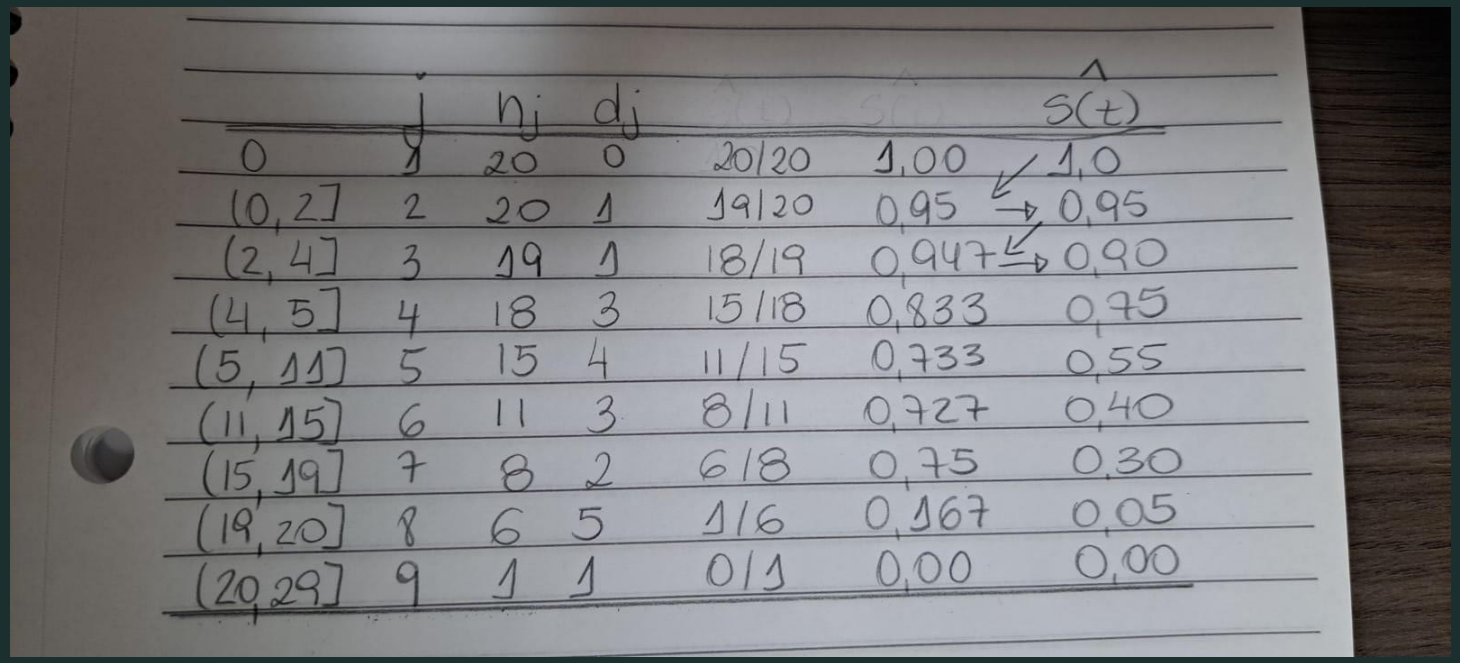

	j	n_j	d_j			$\hat{S}(t)$
0	1	20	0	20/20	1,00	1,0
(0, 2]	2	20	1	19/20	0,95	0,95
(2, 4]	3	19	1	18/19	0,947	0,90
(4, 5]	4	18	3	15/18	0,833	0,75
(5, 11]	5	15	4	11/15	0,733	0,55
(11, 15]	6	11	3	8/11	0,727	0,40
(15, 19]	7	8	2	6/8	0,75	0,30
(19, 20]	8	6	5	1/6	0,167	0,05
(20, 29]	9	1	1	0/1	0,00	0,00

Em R

```
#################################################################
# Estimador de Kaplan Meyer

m1=survfit(Surv(tempo,evento_caso1) ~ 1, data=dados)
m1
summary(m1)
summary(m1,extend=TRUE,times=c(1:29))
ggsurvplot(m1, data=dados,
           fontsize=5,
           censur=T,
           title="Sobrevivência ao Divórcio - Caso 1",
           surv.median.line = "h")
```

```
> summary(m1)
Call: survfit(formula = Surv(tempo, evento_caso1) ~ 1, data = dados)

 time n.risk n.event survival std.err lower 95% CI upper 95% CI
    2     20       1     0.95  0.0487       0.8591        1.000
    4     19       1     0.90  0.0671       0.7777        1.000
    5     18       3     0.75  0.0968       0.5823        0.966
   11     15       4     0.55  0.1112       0.3700        0.818
   15     11       3     0.40  0.1095       0.2339        0.684
   19      8       2     0.30  0.1025       0.1536        0.586
   20      6       5     0.05  0.0487       0.0074        0.338
   29      1       1     0.00     NaN           NA           NA
```

```
> m1
Call: survfit(formula = Surv(tempo, evento_caso1) ~ 1, data = dados)

      n events median 0.95LCL 0.95UCL
[1,] 20     20     15      11      20
>
```

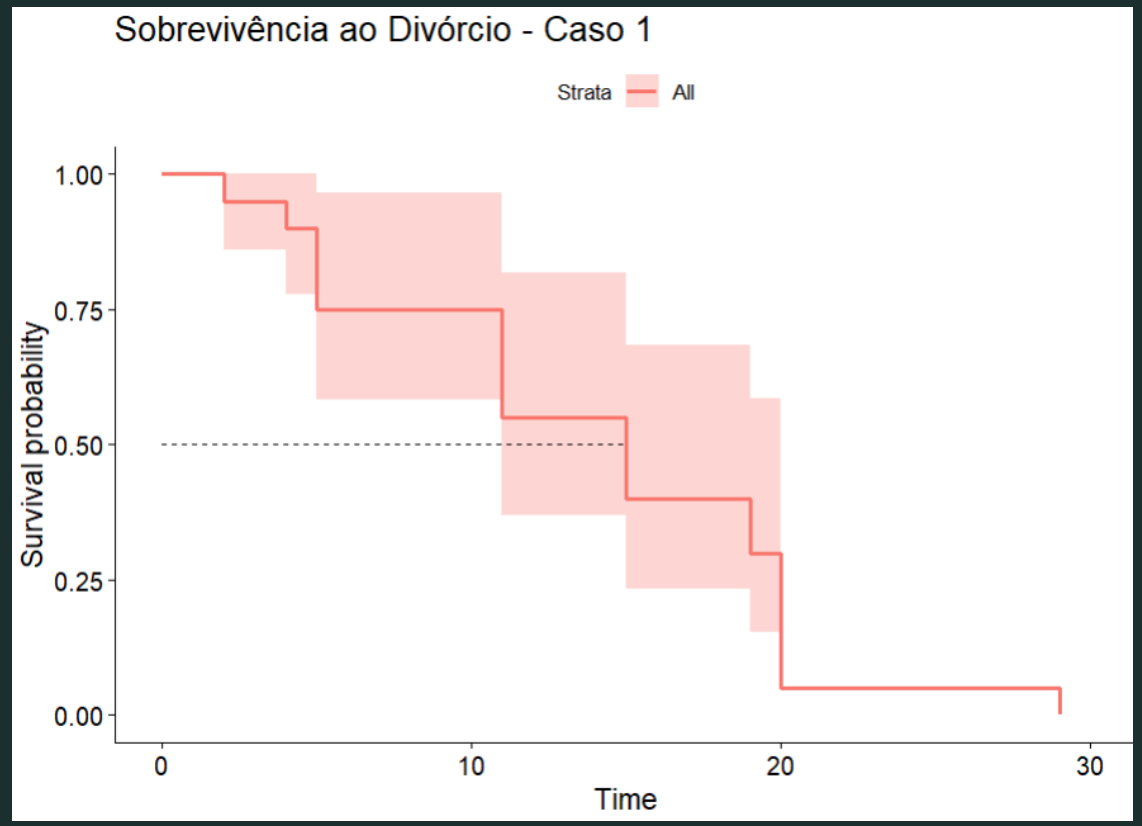

Caso 2 (Com Censura)

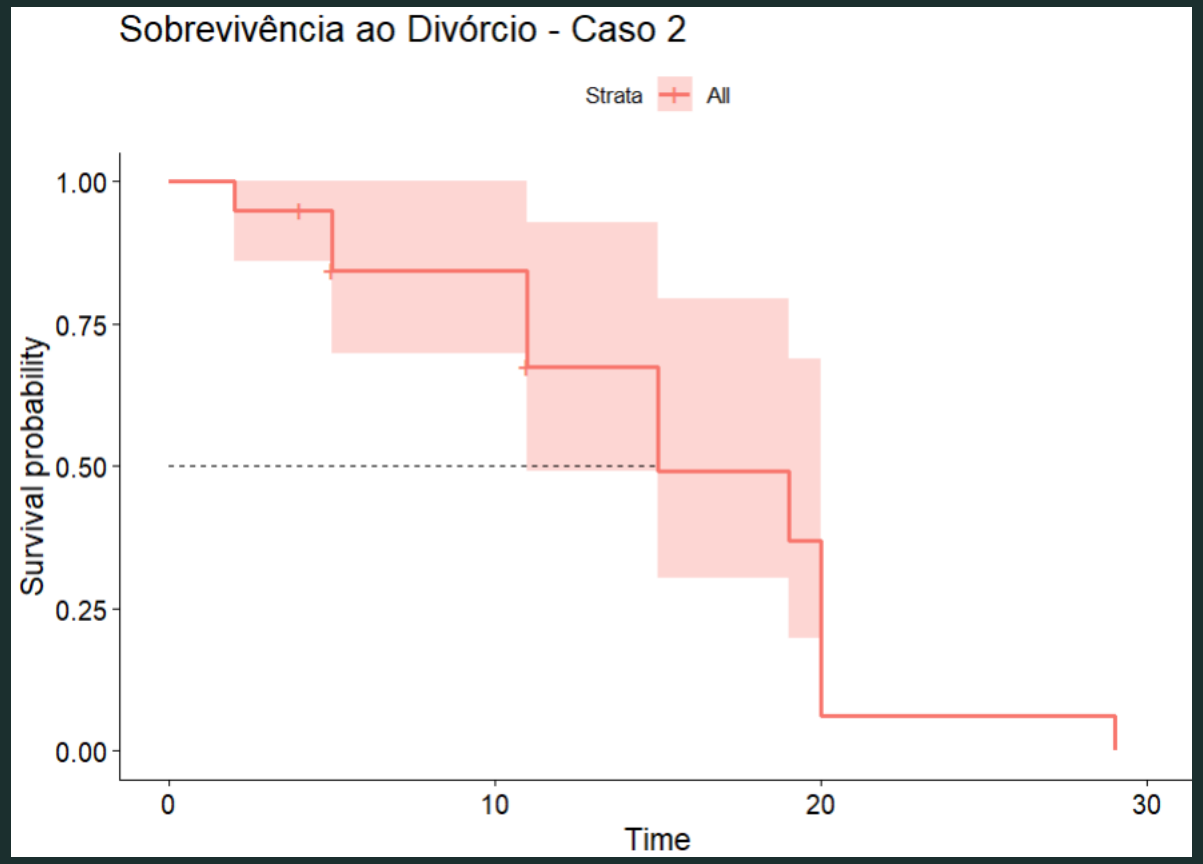


```
> summary(m2)
Call: survfit(formula = Surv(tempo, evento_caso2) ~ 1, data = dados)

 time n.risk n.event survival std.err lower 95% CI upper 95% CI
    2     20       1   0.9500  0.0487      0.85913        1.000
    5     18       2   0.8444  0.0826      0.69707        1.000
   11     15       3   0.6756  0.1094      0.49178        0.928
   15     11       3   0.4913  0.1207      0.30358        0.795
   19      8       2   0.3685  0.1177      0.19705        0.689
   20      6       5   0.0614  0.0594      0.00923        0.409
   29      1       1   0.0000     NaN           NA           NA
>
```

Caso 3 (Com Censura)

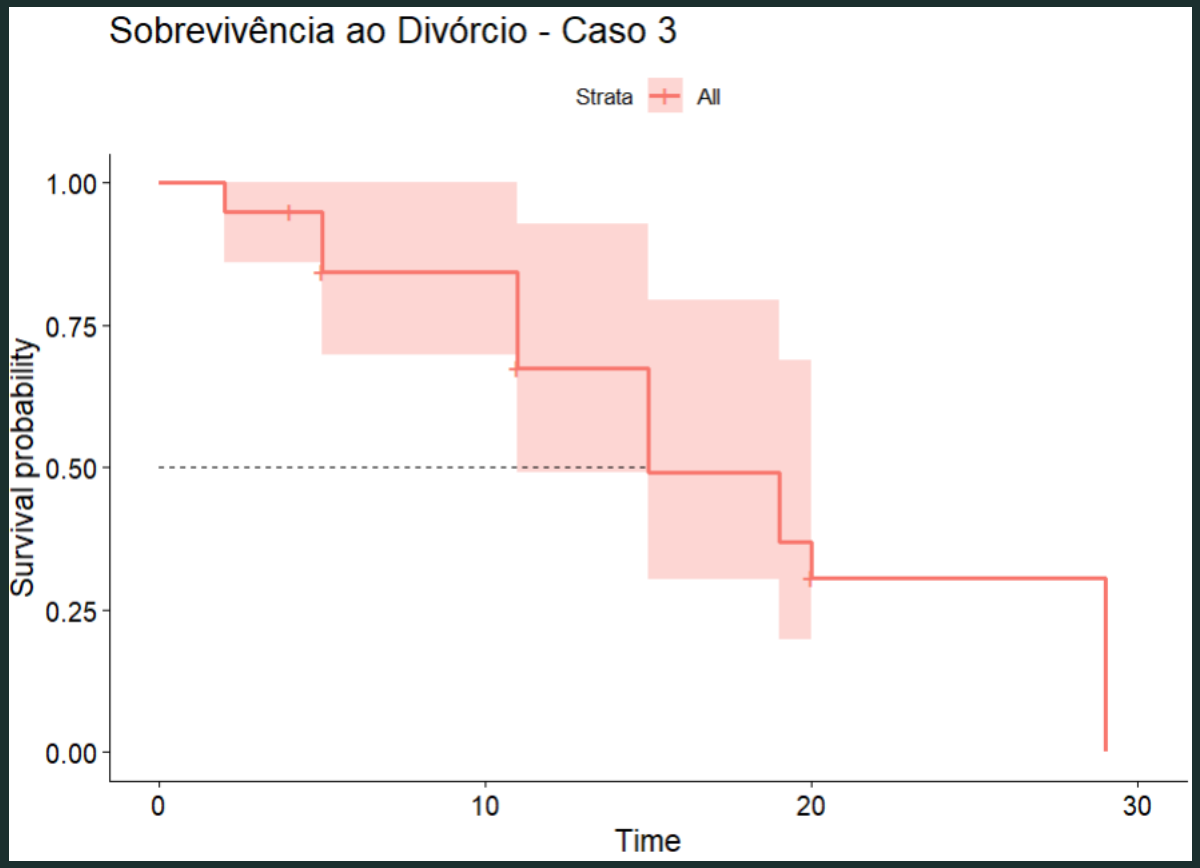


```
> summary(m3)
Call: survfit(formula = Surv(tempo, evento_caso3) ~ 1, data = dados)

 time n.risk n.event survival std.err lower 95% CI upper 95% CI
    2     20       1    0.950  0.0487        0.859        1.000
    5     18       2    0.844  0.0826        0.697        1.000
   11     15       3    0.676  0.1094        0.492        0.928
   15     11       3    0.491  0.1207        0.304        0.795
   19      8       2    0.368  0.1177        0.197        0.689
   20      6       1    0.307  0.1130        0.149        0.632
   29      1       1    0.000     NaN           NA           NA
>
```

Tarefa 2 (individual)

ID	tempo	evento_caso1	evento_caso2	evento_caso3
1	2	1	1	1
2	4	1	0	0
3	5	1	1	1
4	5	1	0	0
5	5	1	1	1
6	11	1	0	0
7	11	1	1	1
8	11	1	1	1
9	11	1	1	1
10	15	1	1	1
11	15	1	1	1
12	15	1	1	1
13	19	1	1	1
14	19	1	1	1
15	20	1	1	0
16	20	1	1	1
17	20	1	1	0
18	20	1	1	0
19	20	1	1	0
20	29	1	1	1

Para os dados de tempo do banco de dados ao lado Criar um caso para censuras que resulte em uma curva KM que não finaliza em zero.

Escrever com tuas palavras um parágrafo dizendo em quais situações a característica de não finalizar em zero acontecerá.

Entregue um arquivo único com:

1. A descrição dos dados (quais tempo são evento e quais são censura)
2. O gráfico de KM
3. O parágrafo