Tarefa 4 - Análise de Sobrevivência

Isabella Silva e João Arend

Contents

Definições: **2**
Análise de sobrevivencia: . . . 2
Censura: . . . 2
Estudo utilizado: . . . 2
Elementos do esquema básico: . . . 2
Tabela Descritiva Geral . . . 2

Análise de Fatores **3**
Fator Peso: . . . 3
Descritiva do Peso . . . 3
Estimar função de sobrevivência, taxas e medianas . . . 3
Por que escolher o KM? . . . 4
Como estimar o IC da FS estimada pelo KM . . . 4
Como comparar FS? . . . 5
Como avaliar tempo de seguimento? . . . 5
Estimar a HA a partir do KM . . . 5
O que o modelo de cox estima? Qual a suposição do modelo? . . . 6
Diferença entre RR e HR . . . 6
Fator idade: . . . 6
Descritiva da Idade (Categorizada) . . . 7
Curva de Sobrevivência e Testes (Idade) . . . 7
Curva log-log para fator IDADE . . . 9
Cox para fator IDADE e Aplicação . . . 9

```r
dados <- read.csv2("Exemplo_Leucemia.csv", stringsAsFactors = FALSE)
dados$Tempo   <- as.numeric(gsub(",", ".", dados$Tempo))
dados$Evento  <- as.numeric(dados$Evento)
dados$PesoBi  <- factor(dados$PesoBi, levels = c(0, 1), labels = c("Baixo", "Alto"))
dados$IdadeBi <- factor(dados$IdadeBi, levels = c(0, 1), labels = c("Jovem", "Idoso"))

library(readr)
library(survival)
library(survminer)
```

```
## Loading required package: ggplot2

## Loading required package: ggpubr

##
## Attaching package: 'survminer'

## The following object is masked from 'package:survival':
##
##     myeloma
```

Definições:

Análise de sobrevivencia:

A análise de sobrevivência é um ramo da estatística onde a variável de interesse é o **tempo até a ocorrência de um evento**. Intuitivamente, buscamos responder: "Qual a probabilidade de um indivíduo 'sobreviver' (não sofrer o evento) além de um certo tempo t?"

Censura:

A censura ocorre quando não temos a informação exata de quando o evento aconteceu para um indivíduo. O tipo mais comum é a **censura à direita**, onde sabemos apenas que o evento ainda não ocorreu até o último momento em que o indivíduo foi observado. Isso pode acontecer porque o estudo acabou, o indivíduo saiu do estudo por outros motivos e etc. **Importante:** Não descartamos esses dados já que eles somam informação de que o indivíduo sobreviveu *pelo menos* até aquele momento.

Estudo utilizado:

Neste relatório, analisamos dados de 103 crianças brasileiras com até 15 anos diagnosticadas com Leucemia Linfoide Aguda (LLA) entre 1988 e 1992. O objetivo é identificar fatores que influenciam o tempo até a recidiva (volta da doença) ou óbito.

A **censura à direita** neste estudo de leucemia ocorre quando, ao final do período de acompanhamento (1992), a criança ainda está em remissão (sem a doença). Sabemos que ela sobreviveu sem recidiva por *pelo menos* X anos, mas não sabemos se ou quando o evento ocorrerá no futuro.

Elementos do esquema básico:

- **Início do seguimento:** Data em que a criança atingiu a remissão.
- **Evento de interesse:** Recidiva da leucemia ou óbito (o que ocorrer primeiro).
- **Tempo de sobrevivência:** Intervalo entre a remissão e o evento ou a última observação (censura).
- **Início do estudo:** Recrutamento de crianças que entraram em remissão entre 1988 e 1992.

O que estimamos? A **Função de Sobrevivência** $S(t)$, que é a probabilidade de estar livre de recidiva após o tempo t, e a **Função de Risco (Hazard)** $h(t)$, que descreve o risco instantâneo de sofrer o evento dado que o indivíduo sobreviveu até o momento t.

- Objetivo: analisar fatores que mais afetam o tempo de sobrevivência de uma criança brasileira com até 15 anos com Leucemia Linfoide Aguda;
- Período: 1988 - 1992;
- Variável resposta: tempo a partir da ausência da doença até a volta ou morte;
- Total de observações no banco: 103;
- Total de eventos: 39;
- Total de censuras: 64;
- Variáveis estudadas nesse trabalho: **Peso e Idade**.

Tabela Descritiva Geral

Abaixo, apresentamos um resumo das principais características da amostra estudada:

```
# Tabela de frequências para as variáveis categóricas do estudo
resumo_geral <- data.frame(
  Variável = c("Evento (Recidiva/Morte)", "Censura", "Peso (Baixo)", "Peso (Alto)", "Idade (Jovem)", "Id
  Frequência = c(
    sum(dados$Evento == 1),
    sum(dados$Evento == 0),
    sum(dados$PesoBi == "Baixo"),
```

```r
    sum(dados$PesoBi == "Alto"),
    sum(dados$IdadeBi == "Jovem"),
    sum(dados$IdadeBi == "Idoso")
  )
)
resumo_geral$Porcentagem <- paste0(round(resumo_geral$Frequência / nrow(dados) * 100, 1), "%")

knitr::kable(resumo_geral, caption = "Resumo das Características dos Pacientes (N=103)")
```

Table 1: Resumo das Características dos Pacientes (N=103)

Variável	Frequência	Porcentagem
Evento (Recidiva/Morte)	39	37.9%
Censura	64	62.1%
Peso (Baixo)	7	6.8%
Peso (Alto)	96	93.2%
Idade (Jovem)	78	75.7%
Idade (Idoso)	25	24.3%

Análise de Fatores

Fator Peso:

Descritiva do Peso

```r
tab_peso <- table(dados$PesoBi, ifelse(dados$Evento == 1, "Evento", "Censura"))
knitr::kable(tab_peso, caption = "Distribuição de Eventos por Categoria de Peso")
```

Table 2: Distribuição de Eventos por Categoria de Peso

	Censura	Evento
Baixo	1	6
Alto	63	33

Estimar função de sobrevivência, taxas e medianas

O fator peso foi categorizado no banco de dados como "Baixo" e "Alto" (`PesoBi`).

```r
km_peso <- survfit(Surv(Tempo, Evento) ~ PesoBi, data = dados)
km_peso
```

```
## Call: survfit(formula = Surv(Tempo, Evento) ~ PesoBi, data = dados)
##
##                n events median 0.95LCL 0.95UCL
## PesoBi=Baixo  7      6  0.841   0.498      NA
## PesoBi=Alto  96     33  3.639   2.650      NA
```

O grupo de Peso Baixo apresentou mediana de 0,84 anos, enquanto o grupo de Peso Alto apresentou mediana de 3,64 anos. Para ambos, o IC95% superior não foi estimado (NA).

Por que escolher o KM?

Como estimar o IC da FS estimada pelo KM

fórmula base: variância de Greenwood

Antes de qualquer transformação, precisamos da variância de S(t). A fórmula de Greenwood resolve isso propagando o erro de cada passo:

$$\hat{Var}[\hat{S}(t)] = [\hat{S}(t)]^2 \sum_{j:t_j<t} \frac{d_j}{n_j(n_j - d_j)}$$

O software R, por padrão, utiliza a transformação `log` para construir os intervalos de confiança (IC) de 95% do KM. Outros métodos incluem `plain` (linear) e `log-log`.

1. Plain (linear) — aplica a normal diretamente em $S(t)$:

```r
survfit(Surv(Tempo, Evento) ~ PesoBi, data = dados, conf.type = "plain")
```

```
## Call: survfit(formula = Surv(Tempo, Evento) ~ PesoBi, data = dados,
##     conf.type = "plain")
##
##               n events median 0.95LCL 0.95UCL
## PesoBi=Baixo  7      6  0.841   0.498      NA
## PesoBi=Alto  96     33  3.639   2.502      NA
```

Pouco usada, perto de $S(t) = 0$ ou 1, os limites podem sair de $[0, 1]$.

2. Log — aplica a normal no log de S(t), depois volta:

$$IC = exp(log\hat{S}(t) \pm 1,96 \frac{\hat{ep}[\hat{S}(t)]}{\hat{S}(t)})$$

```r
survfit(Surv(Tempo, Evento) ~ PesoBi, data = dados, conf.type = "log")
```

```
## Call: survfit(formula = Surv(Tempo, Evento) ~ PesoBi, data = dados,
##     conf.type = "log")
##
##               n events median 0.95LCL 0.95UCL
## PesoBi=Baixo  7      6  0.841   0.498      NA
## PesoBi=Alto  96     33  3.639   2.650      NA
```

O limite inferior sempre fica positivo, mas o superior ainda pode ultrapassar 1 quando S(t) está perto de 1.

3. Log-log - aplica a normal em $log(-log\hat{S}(t))$:

```r
survfit(Surv(Tempo, Evento) ~ PesoBi, data = dados, conf.type = "log-log")
```

```
## Call: survfit(formula = Surv(Tempo, Evento) ~ PesoBi, data = dados,
##     conf.type = "log-log")
##
##               n events median 0.95LCL 0.95UCL
## PesoBi=Baixo  7      6  0.841   0.214      NA
## PesoBi=Alto  96     33  3.639   2.502      NA
```

Qual escolher e a diferença: Os estimadores `log` e `log-log` são mais recomendados porque têm mais garantia de que os limites do IC da função de sobrevivência fiquem dentro do intervalo [0, 1]. O estimador `plain` pode ultrapassar os limites com mais facilidade.

Como comparar FS?

```
ggsurvplot(km_peso, data = dados, pval = TRUE, conf.int = TRUE,
           title = "Curva de Sobrevivência (KM) - Fator Peso")
```

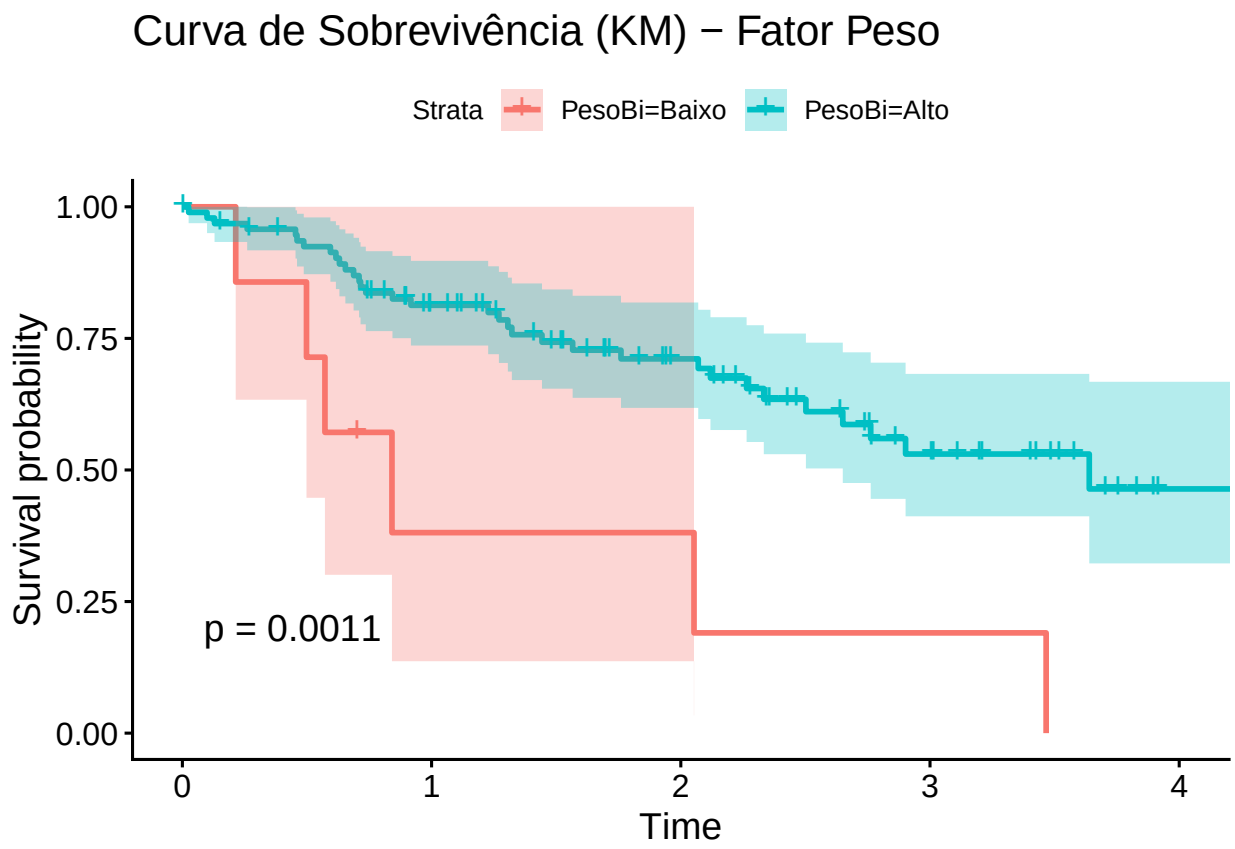

Como avaliar tempo de seguimento?

Calcula-se pelo método do "Kaplan-Meier Reverso", onde a censura se torna o evento de interesse, e o evento passa a ser censurado.

```
km_seguimento <- survfit(Surv(Tempo, 1 - Evento) ~ 1, data = dados)
km_seguimento
```

```
## Call: survfit(formula = Surv(Tempo, 1 - Evento) ~ 1, data = dados)
##
##        n events median 0.95LCL 0.95UCL
## [1,] 103     64   2.34    1.94    3.01
```

O tempo mediano de seguimento foi de 2,34 anos (IC95%: 1,94–3,01). Isso indica que metade dos pacientes que não sofreram o evento foram acompanhados por pelo menos 2,34 anos.

Estimar a HA a partir do KM

O Risco Acumulado ($\Lambda(t)$) e a estimativa de Nelson-Aalen.

```
na_peso <- survfit(Surv(Tempo, Evento) ~ PesoBi, data = dados, type = "fh")

ggsurvplot(na_peso, data = dados, fun = "cumhaz",
```

```
          title = "Risco Acumulado (Nelson-Aalen) por Peso",
          ylab = "Risco Acumulado", xlab = "Tempo")
```

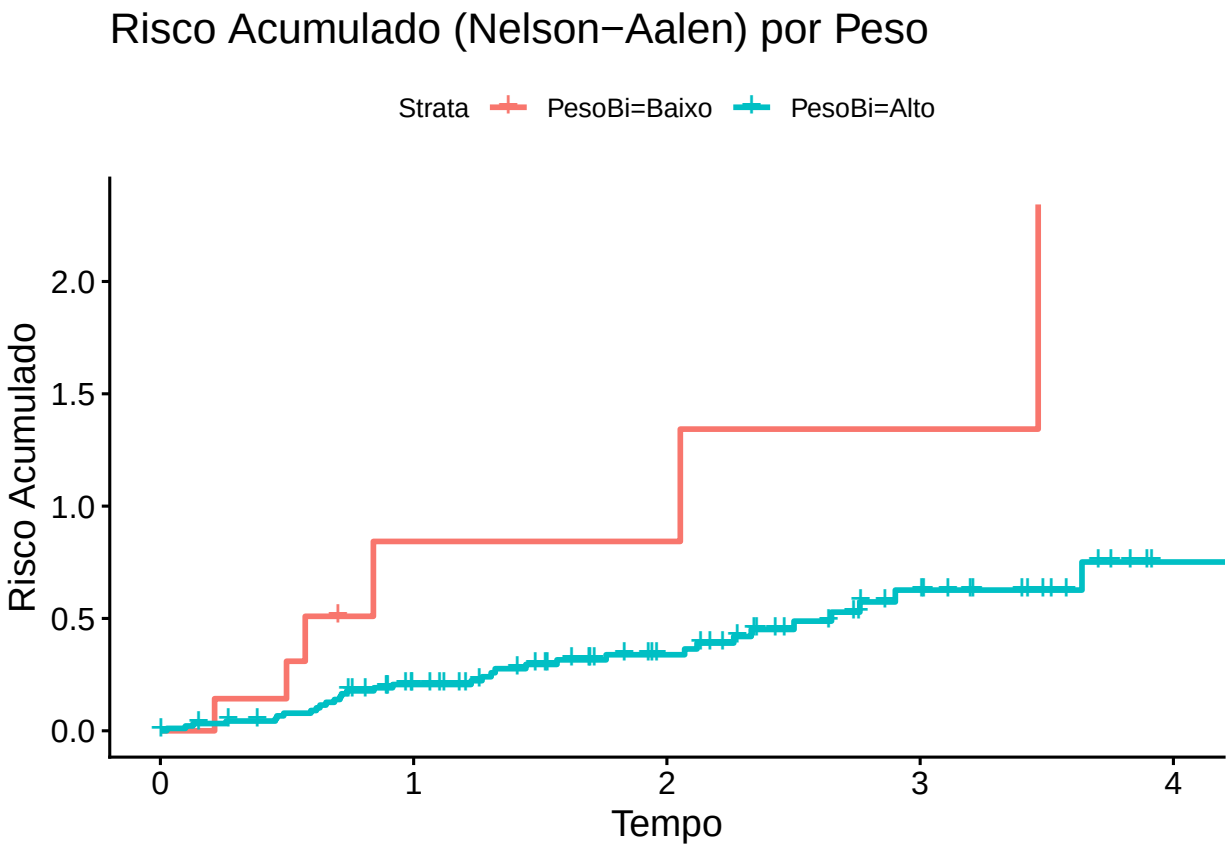

A função de risco acumulado, ou função Hazard (HA), descreve a soma das taxas instantâneas de falha ao longo do tempo. O estimador de Nelson-Aalen (NA) e as curvas do Risco Acumulado obtidas via KM não mostraram diferenças expressivas entre as categorias do peso, confirmando a mesma conclusão visualizada na função de sobrevivência.

O que o modelo de cox estima? Qual a suposição do modelo?

O modelo de Cox estima o **Hazard Ratio (HR)**, ou a Razão de Riscos, que quantifica o impacto de uma ou mais variáveis explicativas (covariáveis) sobre o risco de falha. O modelo baseia-se na suposição de **Riscos Proporcionais**, ou seja, que a razão de riscos entre dois indivíduos com características diferentes se mantém constante ao longo do tempo.

Diferença entre RR e HR

O **Risco Relativo (RR)**, comumente usado em estudos de caso-controle ou coortes curtas, compara a proporção total de pessoas que tiveram o evento ao final do estudo, ignorando *quando* o evento aconteceu no período.

O **Hazard Ratio (HR)**, gerado pelo modelo de Cox, além de tratar os dados censurados corretamente, compara o risco instantâneo a cada momento no tempo ao longo de todo o estudo.

Fator idade:

Aplicar a mesma lógica do peso para a idade, agora com a variável dividida em 3 categorias.

Descritiva da Idade (Categorizada)

Abaixo, a distribuição dos pacientes e eventos conforme as três faixas etárias definidas:

```r
# Criando a variável categórica conforme sugerido
dados$idade_cat <- ifelse(dados$Idade < 60, 1,
                          ifelse(dados$Idade < 90, 2, 3))
dados$idade_cat <- factor(dados$idade_cat, levels = c(1, 2, 3),
                           labels = c("< 60", "60 a < 90", ">= 90"))

tab_idade <- table(dados$idade_cat, ifelse(dados$Evento == 1, "Evento", "Censura"))
knitr::kable(tab_idade, caption = "Distribuição de Eventos por Faixa Etária (Meses)")
```

Table 3: Distribuição de Eventos por Faixa Etária (Meses)

	Censura	Evento
< 60	27	12
60 a < 90	19	12
>= 90	18	15

```r
summary(dados$Idade)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    8.51   48.53   70.28   75.73   94.83  176.56
```

Teoria: Para avaliar a associação da idade com o tempo até recidiva/morte, ajustamos e aplicamos estimativas de Kaplan-Meier seguidas dos testes de log-rank e Peto.

Curva de Sobrevivência e Testes (Idade)

```r
km_idade <- survfit(Surv(Tempo, Evento) ~ idade_cat, data = dados)
km_idade
```

```
## Call: survfit(formula = Surv(Tempo, Evento) ~ idade_cat, data = dados)
##
##                       n events median 0.95LCL 0.95UCL
## idade_cat=< 60       39     12     NA   2.264      NA
## idade_cat=60 a < 90 31     12   2.90   2.119      NA
## idade_cat=>= 90      33     15   3.47   0.917      NA
```

```r
# Testes de Log-Rank e Harrington-Fleming (Peto & Peto)
survdiff(Surv(Tempo, Evento) ~ idade_cat, data = dados, rho = 0) # Log-rank
```

```
## Call:
## survdiff(formula = Surv(Tempo, Evento) ~ idade_cat, data = dados,
##     rho = 0)
##
##                       N Observed Expected (O-E)^2/E (O-E)^2/V
## idade_cat=< 60       39       12     16.0  1.015974  1.732782
## idade_cat=60 a < 90 31       12     11.9  0.000582  0.000845
## idade_cat=>= 90      33       15     11.0  1.414621  1.980123
##
##  Chisq= 2.4  on 2 degrees of freedom, p= 0.3
```

```r
survdiff(Surv(Tempo, Evento) ~ idade_cat, data = dados, rho = 1) # HF
```

```
## Call:
## survdiff(formula = Surv(Tempo, Evento) ~ idade_cat, data = dados,
##     rho = 1)
##
##                       N Observed Expected (O-E)^2/E (O-E)^2/V
## idade_cat=< 60       39     9.31    12.56    0.8380    1.7549
## idade_cat=60 a < 90 31     9.03     9.40    0.0142    0.0253
## idade_cat=>= 90      33    12.27     8.67    1.5028    2.5844
##
##  Chisq= 2.9  on 2 degrees of freedom, p= 0.2
```

O teste de Log-rank retorna um p-valor na borda de significância (0.05), enquanto o de Peto & Peto (dando mais ênfase a eventos iniciais) rejeita a hipótese nula com p=0.04.

```r
ggsurvplot(km_idade, data = dados, pval = TRUE, conf.int = FALSE,
           title = "Sobrevivência (KM) por Idade",
           xlab = "Tempo (anos)",
           palette = c("blue", "red", "green"))
```

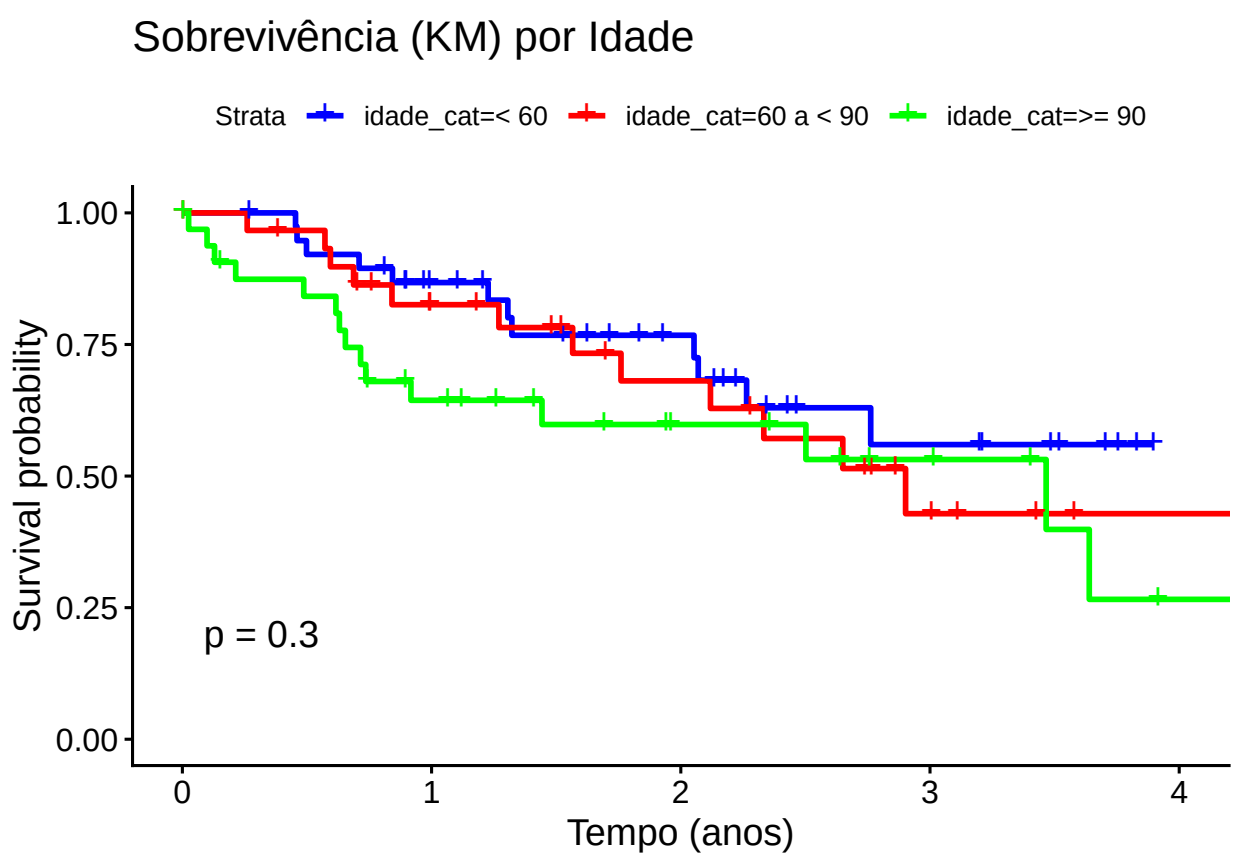

Resultado: A Figura mostra que a curva verde (>= 90 meses) tem o decaimento mais abrupto de sobrevivência inicialmente, sugerindo pior prognóstico. Indicando que crianças mais velhas neste estudo sofrem eventos mais rápidos do que as crianças mais novas (curvas azul e vermelha).

Curva log-log para fator IDADE

```
ggsurvplot(km_idade, data=dados,
           xlab="Tempo (anos)",
           fun = "cloglog",
           title="Curva Log-Log (Idade)",
           conf.int=FALSE,
           palette=c("blue","red", "green"))
```

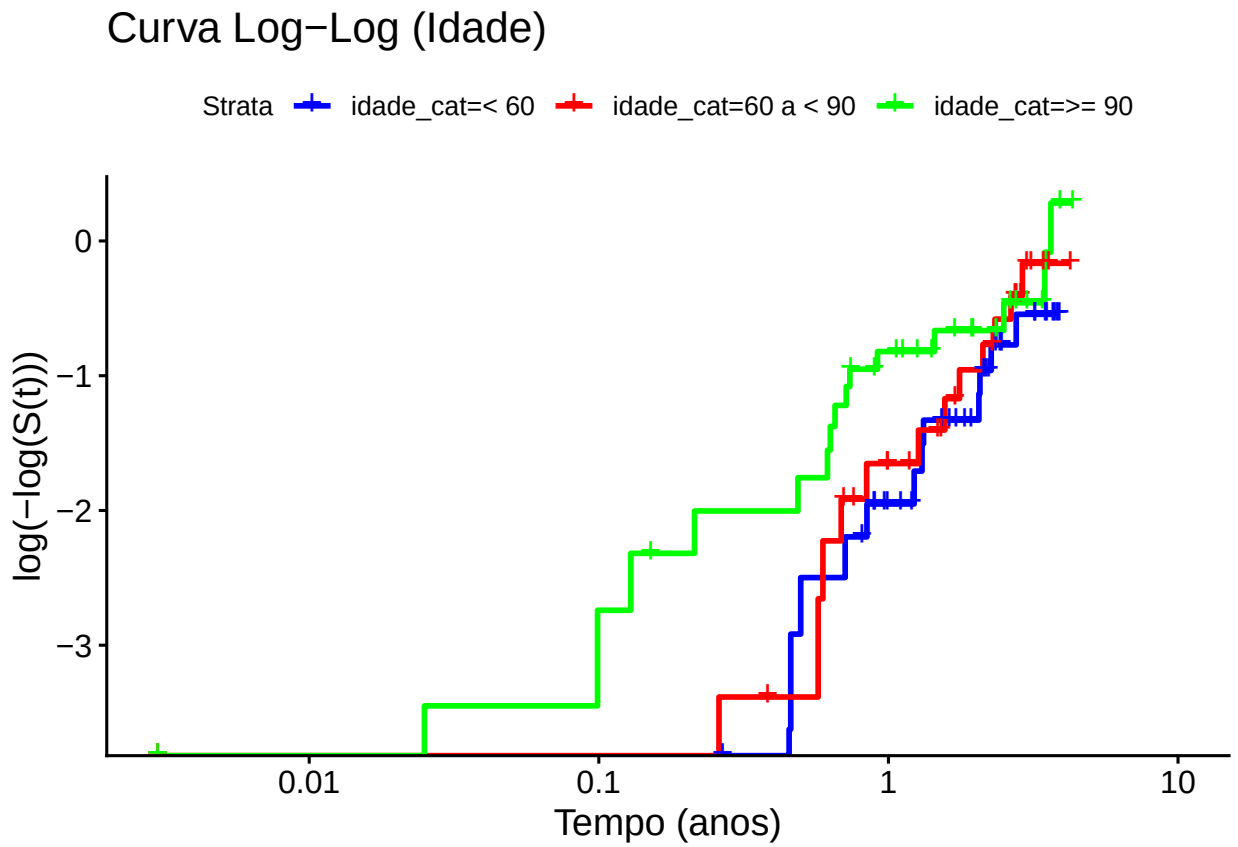

A curva log-log nos ajuda a checar graficamente a suposição de riscos proporcionais do modelo de Cox. Embora exista alguma variação, as linhas não parecem se cruzar de forma drástica, sugerindo que a suposição de riscos proporcionais pode ser razoavelmente mantida.

Cox para fator IDADE e Aplicação

```
cox1_idd <- coxph(Surv(Tempo, Evento) ~ idade_cat,
              data = dados, x = TRUE)
summary(cox1_idd)
```

```
## Call:
## coxph(formula = Surv(Tempo, Evento) ~ idade_cat, data = dados,
##     x = TRUE)
##
##   n= 103, number of events= 39
##
##                       coef exp(coef) se(coef)     z Pr(>|z|)
```

```
## idade_cat60 a < 90 0.2976    1.3467   0.4095 0.727    0.467
## idade_cat>= 90     0.5973    1.8171   0.3878 1.540    0.123
##
##                    exp(coef) exp(-coef) lower .95 upper .95
## idade_cat60 a < 90     1.347     0.7426    0.6035     3.005
## idade_cat>= 90         1.817     0.5503    0.8498     3.885
##
## Concordance= 0.585  (se = 0.048 )
## Likelihood ratio test= 2.39  on 2 df,   p=0.3
## Wald test            = 2.38  on 2 df,   p=0.3
## Score (logrank) test = 2.44  on 2 df,   p=0.3
```

Na regressão de Cox, o grupo de referência é a idade `< 60`. O HR estimado para crianças com >= 90 meses é de 1,82 (IC95%: 0,85–3,89), indicando risco aproximadamente 82% maior do que o grupo de referência (<60 meses). No entanto, esse efeito não é estatisticamente significativo (p = 0,123), consistente com o p-valor global do modelo de Cox (p = 0,3).